



Programa  
Universitario  
de Estudios  
del Desarrollo  
UNAM

# Inferencia bayesiana de la hipótesis nula

Dr. Héctor Nájera

Dr. Curtis Huffman

# Nipótesis nula y descubrimiento

```
. regress bwght cigs male parity faminc faminc2
```

Source	SS	df	MS	Number of obs	=	1,387
Model	20057634.7	5	4011526.94	F(5, 1381)	=	12.54
Residual	441644355	1,381	319800.402	Prob > F	=	0.0000
Total	461701990	1,386	333118.319	R-squared	=	0.0434
				Adj R-squared	=	0.0400
				Root MSE	=	565.51

bwght	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
cigs	-13.25496	2.588155	-5.12	0.000	-18.3321	-8.177817
male	91.00571	30.45073	2.99	0.003	31.27103	150.7404
parity	47.51602	17.07493	2.78	0.005	14.02041	81.01163
faminc	8.660125	3.013622	2.87	0.004	2.748353	14.5719
faminc2	-.0826576	.0414853	-1.99	0.047	-.1640386	-.0012765
_cons	3115.172	57.80237	53.89	0.000	3001.782	3228.562

¿De qué hablamos cuando hablamos de esto?





Rechazando la nula (Meehl paradox):

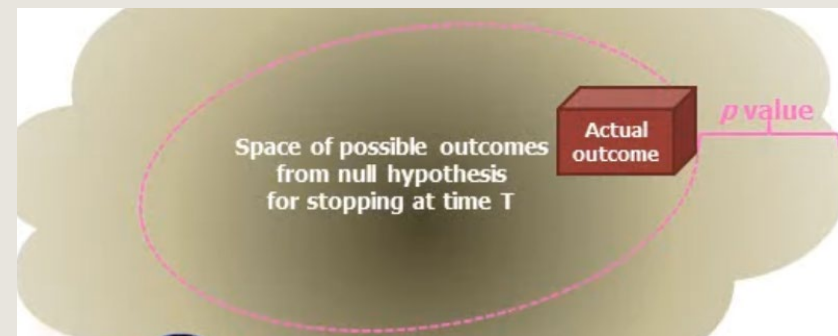
1. La teorías deberían ser más difíciles de confirmar a medida que tenemos más precisión (Todas las teorías están mal)
2. ¿La teoría se confirma rechazando la nula?
3. La nula no puede ser exactamente verdadera
4. Rechazar la nula es más fácil a medida que la precisión aumenta!

# Solución a la paradoja de Meehl

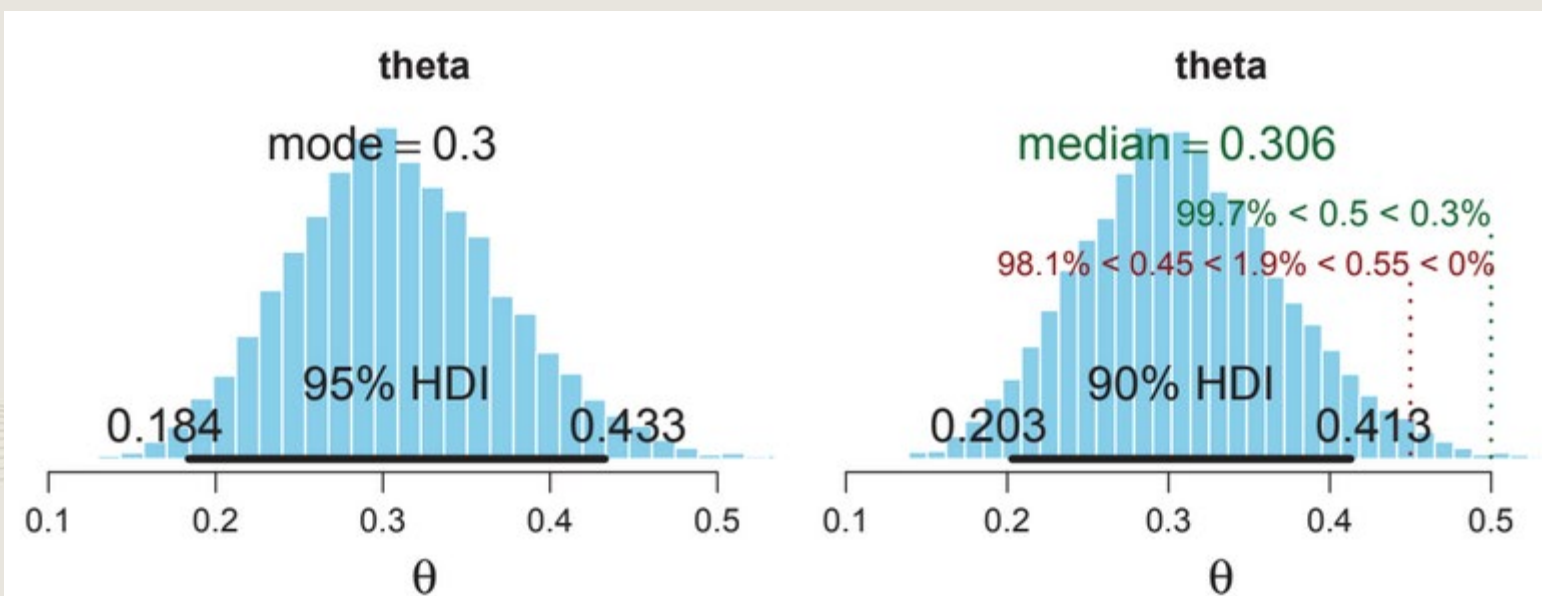
- Buscar aceptar el valor que se predice y no buscar rechazar un valor nulo no predicho
- Esto significa aumentar la precisión de la predicción del valor predicho

AH!

- New statistics: P-values  $< .001$ , Tamaños de efecto, intervalos de confianza y meta análisis como medios para evitar los problemas asociados a pruebas de significancia de las hipótesis nula (NHST).
- Pero como vimos la clase pasada, esto no lo resuelve.
- P-value: Es la probabilidad de que el estadístico (t) su hubiera obtenido de la nula (dada cierta regla respecto al tamaño de los resultados posibles).



- La precisión es la meta
- HDI: Medición de la precisión del valor posterior del parámetro





# Bayes e hipótesis nulas. Dos caminos

- ¿Es creíble el valor “nulo” de un parámetro?
  1. Estimación de parámetros: ¿el valor de interés “cae” dentro del HDI?
  2. Comparación de modelos con diferentes a prioris (según los diferentes valores que admitan del parámetro)






# Algunas consideraciones de la inferencia bayesiana

# Hipótesis: Diferencias entre dos grupos












Priors: Qué sabemos de cada parámetro antes de estos datos

Los datos de cada grupo se describen con distribuciones  $t$  usando parámetros:  $\mu$ ,  $\nu$  y  $\sigma$

Los datos “fijos”







# Combinando las posteriores

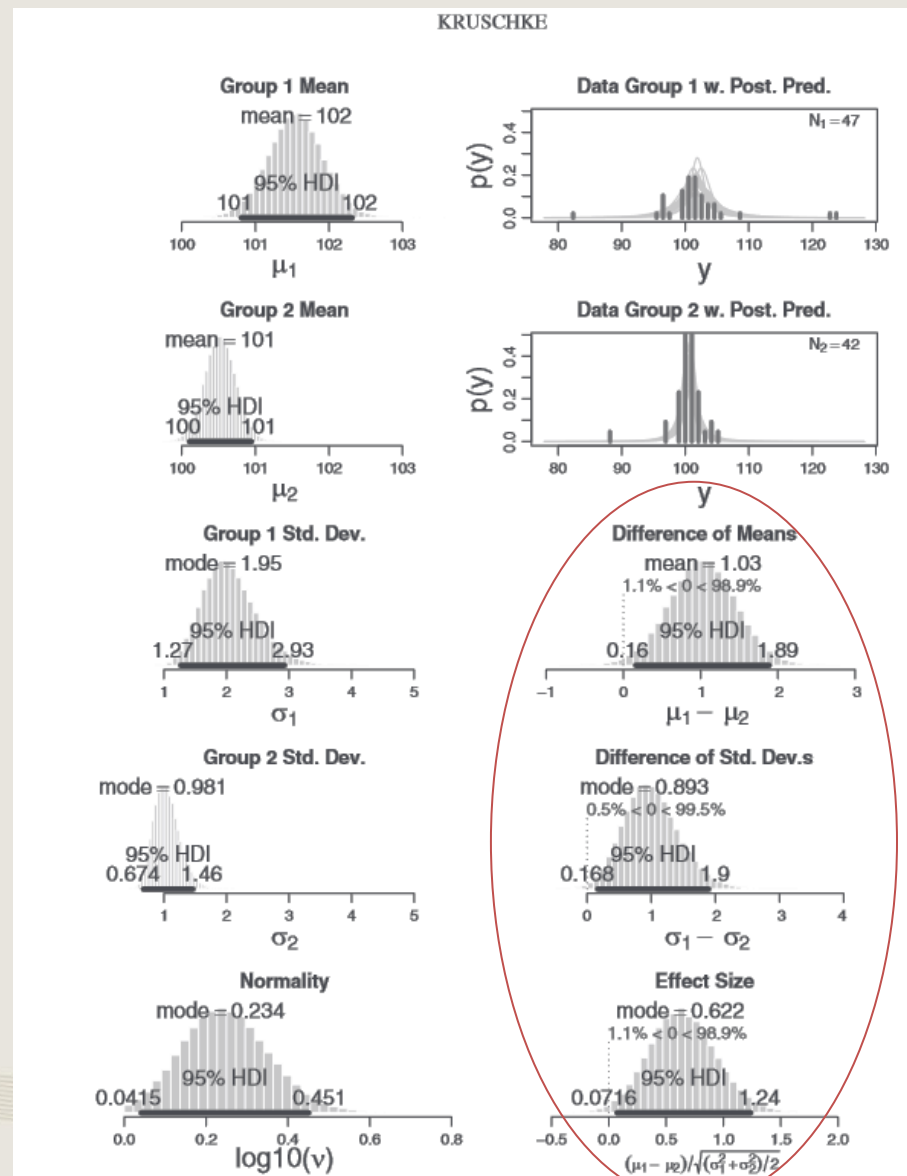
El computo bayesiano ofrece distribuciones de los valores posibles de los parámetros de interés:


Diferencia de medias, de escala (dispersión) y del tamaño del efecto

$$\mu_1 - \mu_2$$

$$\sigma_1 - \sigma_2$$

$$\left( \mu_1 - \mu_2 \sqrt{\frac{\sigma_1^2 + \sigma_2^2}{2}} \right)$$



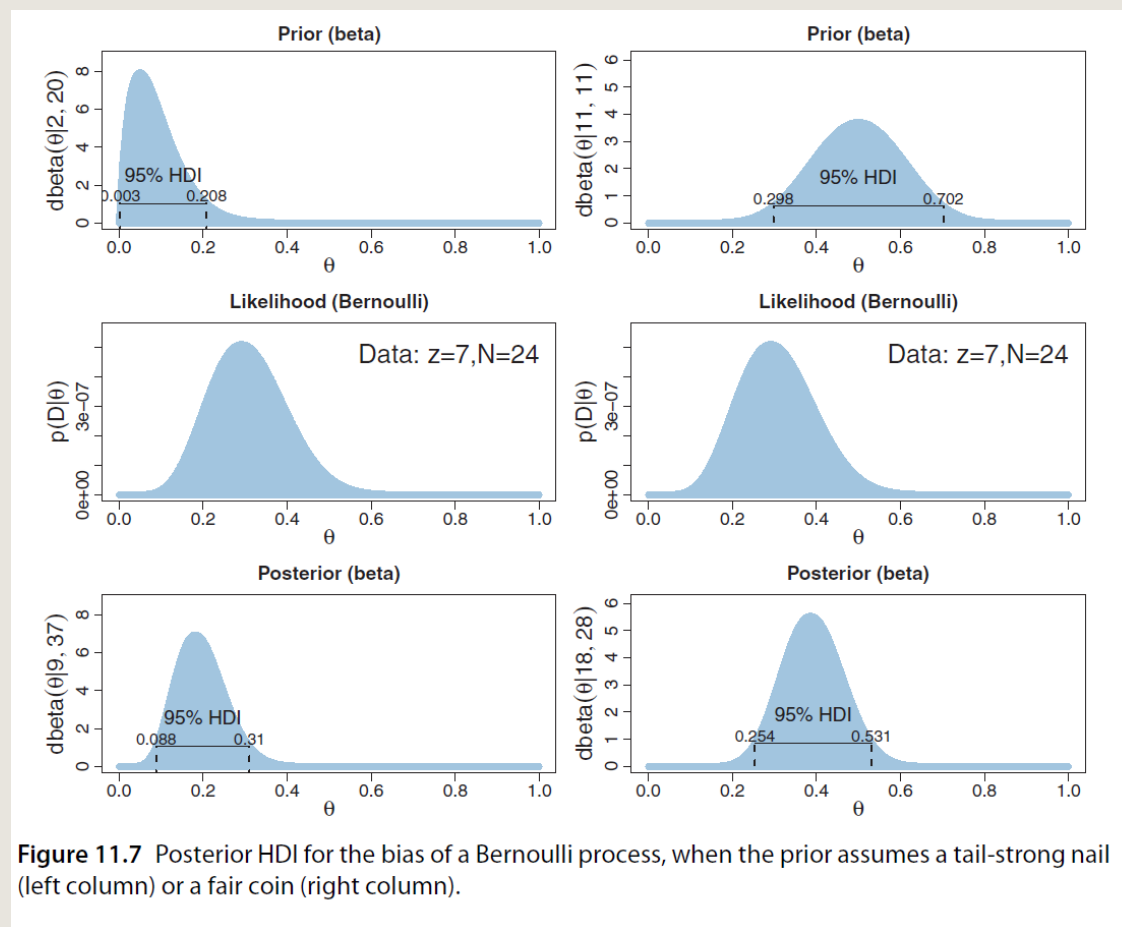


**FIGURE 6 |** Posterior estimate for difference of groups in Solari et al.<sup>36</sup> The third group is credibly different from the mean of the other eight groups.

# HDI Bayesianos

El HDI de 95 % son los valores de  $\Theta$  que tienen al menos ese nivel mínimo de credibilidad posterior.

- A diferencia del IC
  - El HDI tiene una interpretación directa en términos de la credibilidad de los valores de  $\Theta$
  - Es explícitamente acerca de  $p(\Theta|D)$ , que es exactamente de lo que queremos hablar
  - El HDI no depende del diseño de la investigación (el número de pruebas)
  - El HDI responde a las creencias a priori de las investigadoras, como debe ser.



# Bayes vs frecuencias

Tenemos distribuciones completas de los valores de los parámetros

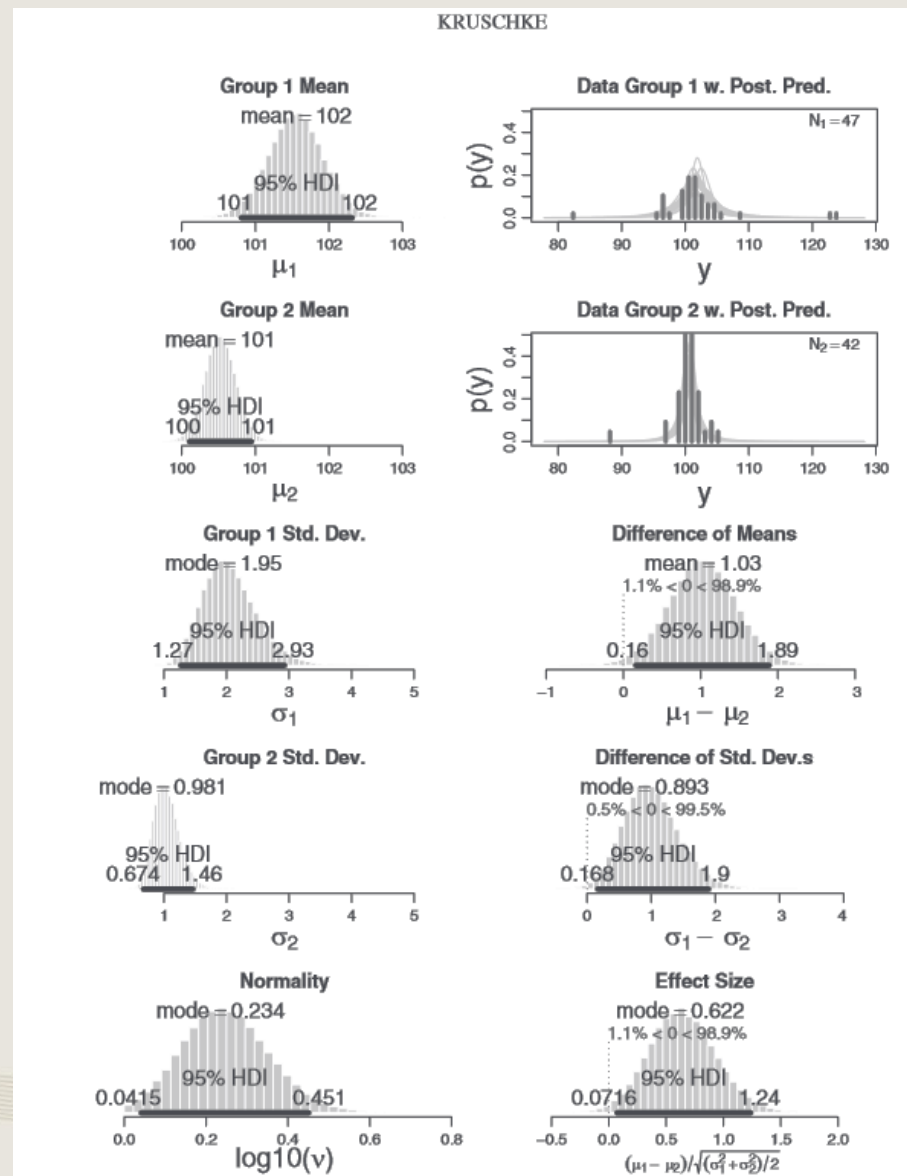
- No solo un estimador puntual

Tenemos precision explícita de los parámetros de interés

- No afectadas por las intenciones de muestreo y de prueba

Modelo flexible que es robusto a valores extremos

- No hay supuesto de normalidad





# Evaluación de hipótesis nula en Bayes

¿Qué hacer si quieres evaluar la probabilidad de un valor nulo?

Dos caminos:

1. Estimación vía parámetros: Región de Equivalencia Práctica (ROPE) y el Intervalo de más alta densidad (HDI)
2. Comparación bayesiana de modelos: Decisión basada en factores bayesianos (Bayes factors)

# I. Estimación de parámetros

Usa la distribución posterior para discernir los valores creíbles del parámetro.



Considere un valor de referencia a evaluar del parámetro de interés: 0,  $-1$  -  $1$ , 100 – 200.

- Región de equivalencia en la práctica (ROPE): **rango (del parámetro) considerado como el mismo en términos prácticos.**
- Pero, ¿cómo se determina la ROPE?
  - Estadística vs Teóricamente significativo






# Region of practical equivalence (ROPE)




# Estimación de parámetros

- Regla de decisión
  - El valor de un parámetro es declarado como **no creíble**, o rechazado, si su ROPE yace fuera del HDI relevante (típicamente el de 95 %) de su distribución posterior.




# Estimación de parámetros

- Regla de decisión
  - El valor de un parámetro es declarado **aceptado** si su ROPE contiene completamente el HDI relevante (típicamente el de 95 %) de su distribución posterior.




# Estimación de parámetros

- Regla de decisión
  - El valor de un parámetro es declarado **aceptado** si su ROPE contiene completamente el HDI relevante (típicamente el de 95 %) de su distribución posterior.




# Estimación de parámetros

- Regla de decisión
  - ¿Qué hacer si el HDI y la ROPE traslapan, sin que la ROPE cubra la HDI por completo (ninguna de las condiciones anteriores se satisface)?



# Estimación de parámetros

- Regla de decisión
  - ¿Qué hacer si el HDI y la ROPE traslapan, sin que la ROPE cubra la HDI por completo (ninguna de las condiciones anteriores se satisface)?



# No siempre el 95% es simétrico

- Esto es importante para las desviaciones estándar
- Pero también para cierto tipo de parámetros en modelos espaciales o en la estimación de valores atípicos


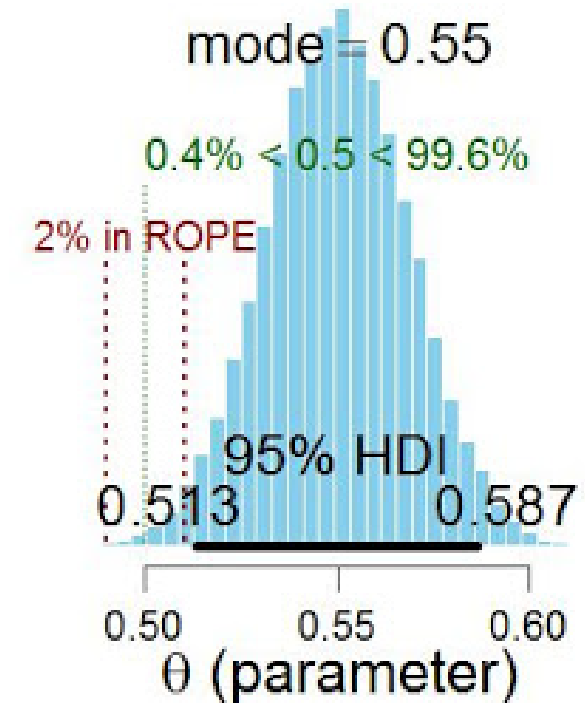


Figure 12.2: A skewed distribution has different 95% highest density interval (HDI) than 95% equal-tailed interval (ETI). Copyright © Kruschke, J. K. (2014). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan. 2nd Edition*. Academic Press / Elsevier.



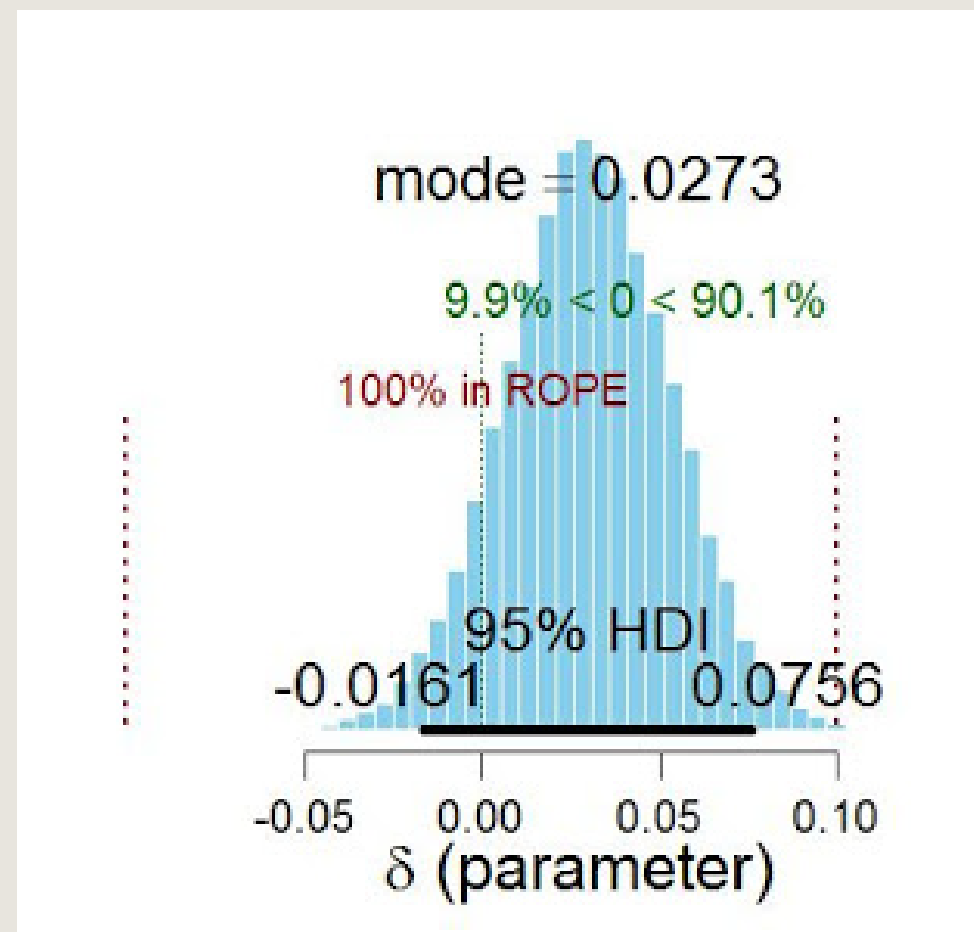
# Estimación de parámetros

- Regla de decisión
  - El valor de un parámetro es declarado como **no creíble**, o rechazado, si su ROPE yace fuera del HDI relevante (típicamente el de 95 %) de su distribución posterior.




# Estimación de parámetros

- Regla de decisión
  - El valor de un parámetro es declarado **aceptado** si su ROPE contiene completamente el HDI relevante (típicamente el de 95 %) de su distribución posterior.



# Estimación de parámetros

- Regla de decisión
  - ¿Qué hacer si el HDI y la ROPE traslapan, sin que la ROPE cubra la HDI por completo (ninguna de las condiciones anteriores se satisface)?





# Estimación de parámetros

---

- No olvidar la inestabilidad de las fronteras de las HDI debido a la aleatoriedad del MCMC
- Es importante advertir que la regla de decisión es independiente de la inferencia bayesiana (la parte bayesiana se acaba en la estimación de la distribución posterior)

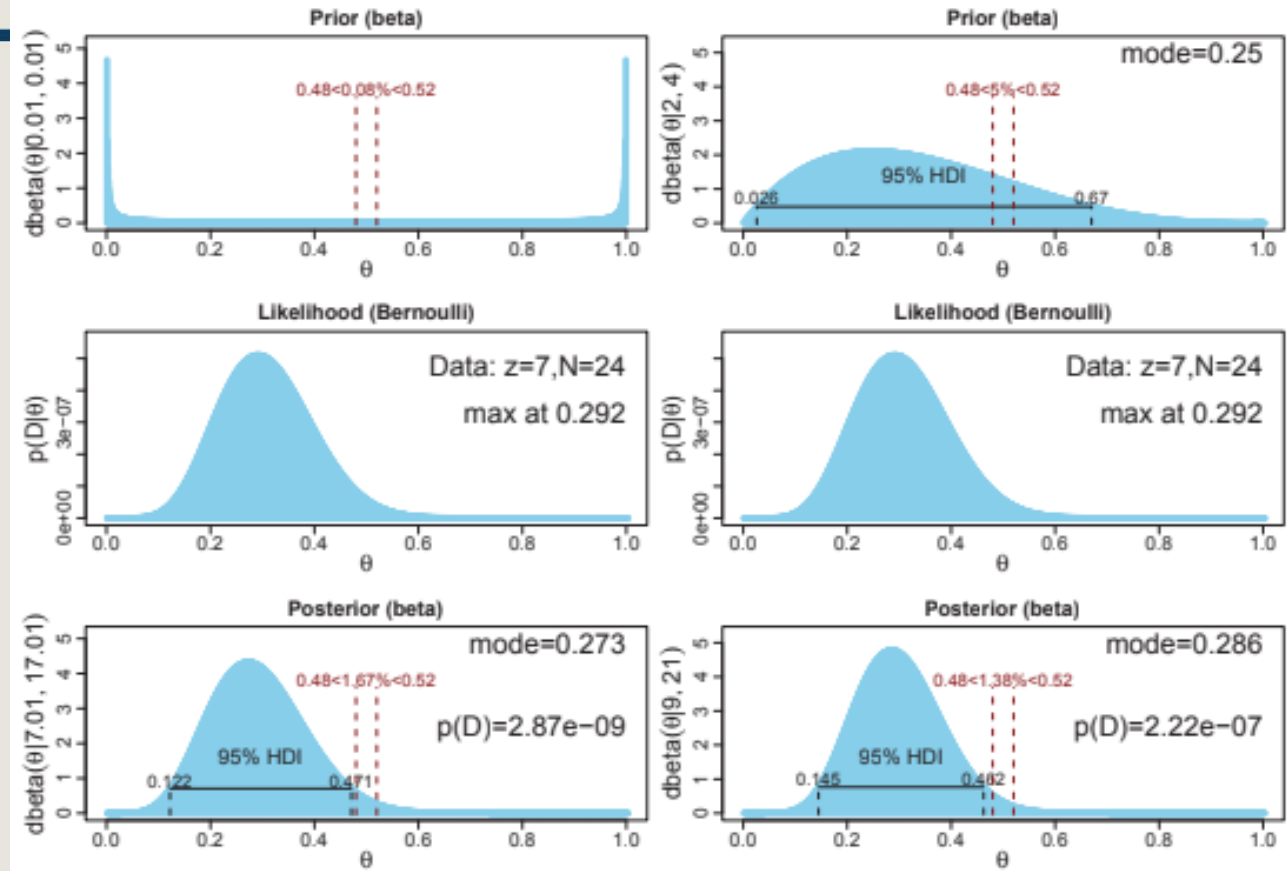



Figure 12.3: Left column: Haldane prior. Right column: Mildly informed prior. Vertical dashed lines mark a ROPE from 0.48 to 0.52. Annotation above the dashed lines indicates the percentage of the distribution within the ROPE. Copyright © Kruschke, J. K. (2014). *Doing Bayesian Data Analysis: A Tutorial with R, JAGS, and Stan. 2nd Edition*. Academic Press / Elsevier.


## 2. Estimación de la nula vía modelos

- Planteamos la pregunta:
  - Estimación puntual del valor nulo v distribución de posibilidades



# Que debemos de pensar de estos modelos

- *Marginal likelihood*
- $P(D|\theta_1)p(\theta_1|m=1)d\theta_1$  **vs**  $P(D|\theta_2)p(\theta_2|m=2)d\theta_2$
- Si tomamos la razón de las marginales: Bayes factor







# Clase de hoy: Inferencia con las posteriores

```
. regress bwght cigs male parity faminc faminc2
```

Source	SS	df	MS	Number of obs	=	1,387
Model	20057634.7	5	4011526.94	F(5, 1381)	=	12.54
Residual	441644355	1,381	319800.402	Prob > F	=	0.0000
				R-squared	=	0.0434
				Adj R-squared	=	0.0400
Total	461701990	1,386	333118.319	Root MSE	=	565.51

bwght	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]
cigs	-13.25496	2.588155	-5.12	0.000	-18.3321 -8.177817
male	91.00571	30.45073	2.99	0.003	31.27103 150.7404
parity	47.51602	17.07493	2.78	0.005	14.02041 81.01163
faminc	8.660125	3.013622	2.87	0.004	2.748353 14.5719
faminc2	-.0826576	.0414853	-1.99	0.047	-.1640386 -.0012765
_cons	3115.172	57.80237	53.89	0.000	3001.782 3228.562





# Consideraciones: Estimación de parámetros

- No olvidar la inestabilidad de las fronteras de las HDI debido a la aleatoriedad del MCMC
- Es importante advertir que la regla de decisión es independiente de la inferencia bayesiana (la parte bayesiana se acaba en la estimación de la distribución posterior)



# Próxima clase

---

